Self-Distillation Enables Continual Learning 詳細版

IRLとの理論的な関係にフォーカス

目的

- 要約版の補足として、SDFTの理論的立ち位置を整理
- 特に「なぜIRL的に解釈できるか」を式で追う
- 実験結果は必要最小限で再掲し、理論と接続する

問題設定: 継続学習で何が難しいか

- SFTはoff-policy imitation
  - 学習時と推論時の状態分布がずれやすい
  - 継続学習で忘却を起こしやすい
- RLはon-policy化できるが、報酬関数が必要
- 実務では「demonstrationはあるが報酬はない」場面が多い

SDFTの基本設計

- student: $\pi_\theta(\cdot \mid x)$
- teacher: $\pi(\cdot \mid x, c)$
  - c: 入力 x に対応するexpert demonstration
- student rollout $y \sim \pi_\theta(\cdot \mid x)$ 上で
  reverse KLを最小化

$$L(\theta) = D_{KL}(\pi_\theta(\cdot|x) \| \pi(\cdot|x, c))$$

手法図（Figure 2）

- 同一モデルを条件違いでteacher/student化
- 報酬を明示設計せず、分布差を学習信号にする

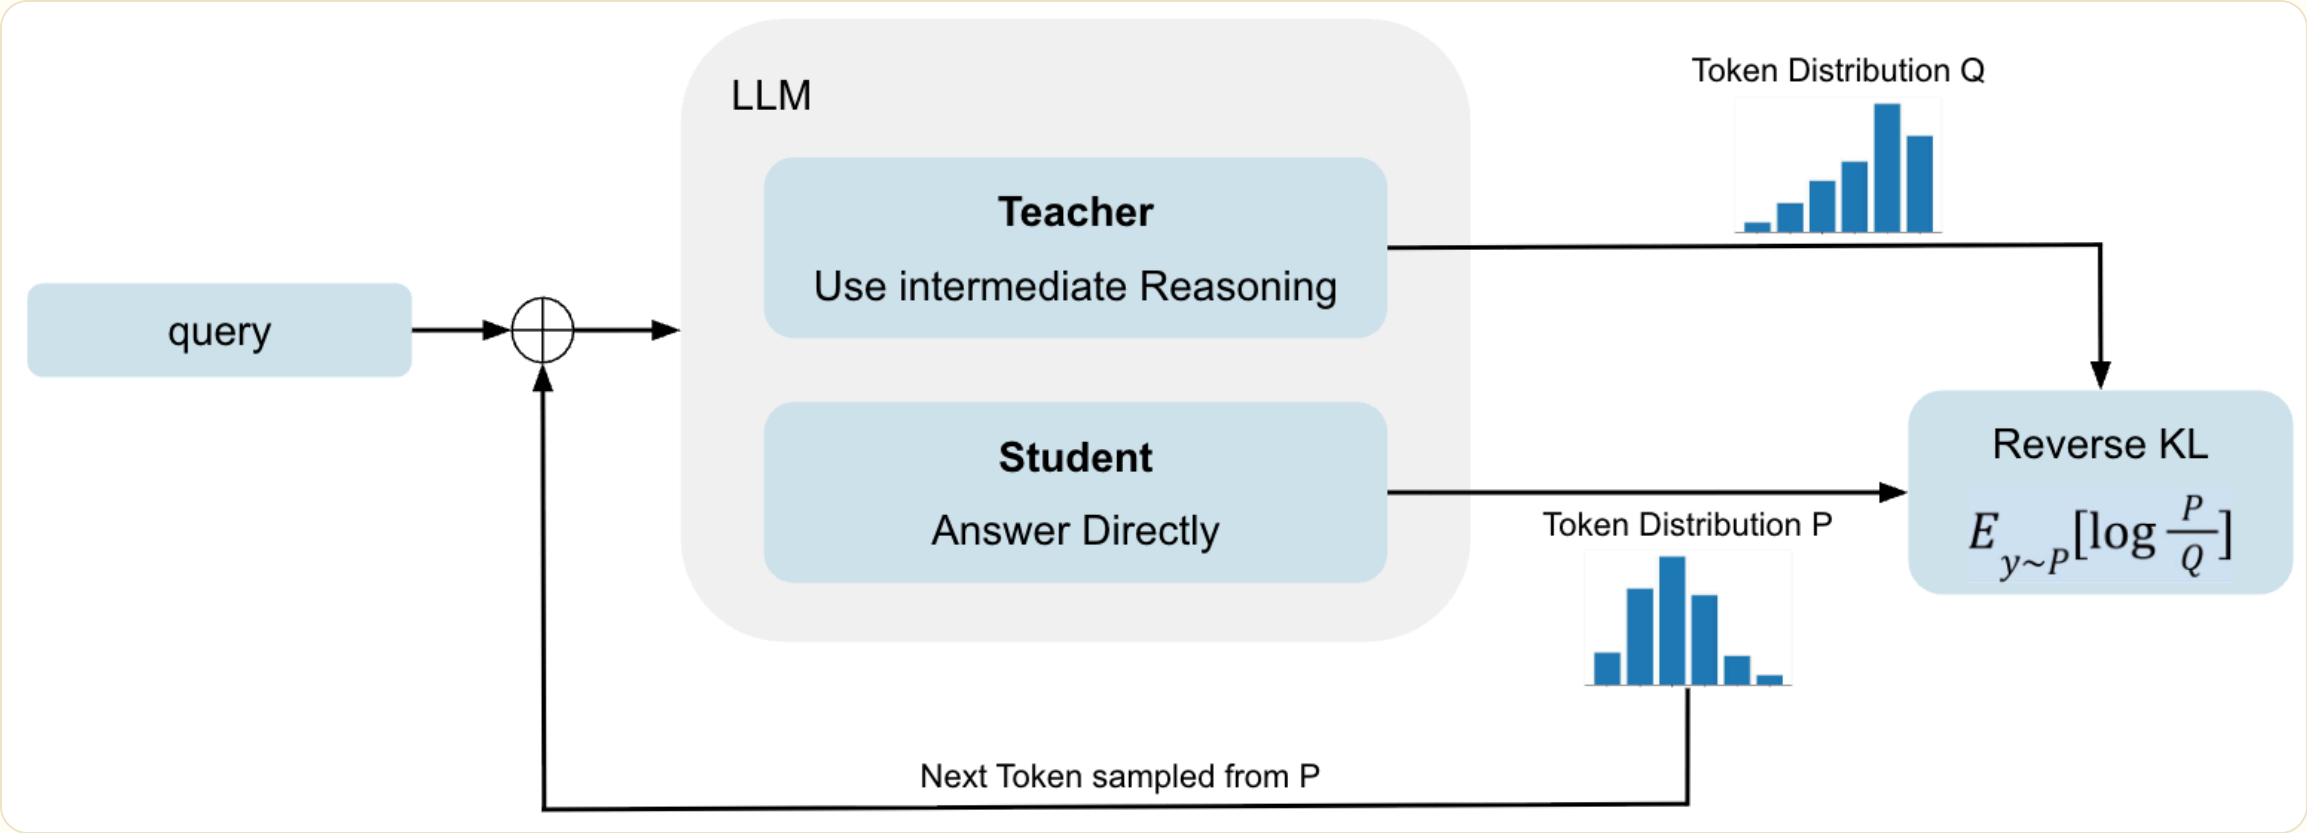

IRLとの関係 1: trust-region RL

論文の出発点は trust-region regularized RL:

$$\pi_{k+1} = \arg\max_{\pi} \ \mathbb{E}_{y\sim\pi}[r(y,x)] - \beta D_{KL}(\pi(\cdot|x)\|\pi_k(\cdot|x))$$

この最適解はtilted distributionで書ける:

$$\pi^*_{k+1}(y|x) \propto \pi_k(y|x)\exp(r(y,x)/\beta)$$

IRLとの関係 2: 報酬の逆算

上式を並べ替えると、最適方策と現方策の比で報酬を表せる:

$$r(y, x) = \beta \left[\log \pi^*_{k+1}(y|x) - \log \pi_k(y|x) \right] + C$$

通常IRLでは π^*_{k+1} が未知なので、
ここをどう近似するかが難しい。

IRLとの関係 3: In-Context Assumption

SDFTのキー仮定:

$$\pi^*_{k+1}(y|x) \approx \pi(y|x, c)$$

- demonstrationを見た同一モデルの条件付き方策が「次ステップの望ましい方策」を近似するとみなす
- これにより暗黙報酬を定義できる:

$$r(y, x, c) = \log \pi(y|x, c) - \log \pi_k(y|x)$$

IRLとの関係 4: reverse KLとの同値性

自己回帰分解でtoken-level rewardへ展開すると、
policy gradientは期待値でreverse KL目的に一致する。

直感:

- teacherが「demonstration付きで見たときの望ましい分布」
- studentが「現在の自分の分布」
- そのlog-ratioを報酬と見た更新が、SDFTの蒸留損失と整合

=> **SDFTは reward-free だが IRL的なon-policy更新として読める**

SDFTは何を置き換えるのか

- 置き換え対象: 「demonstrationからのoff-policy SFT」
- 置き換えないもの: rewardありのon-policy RLそのもの
- 補完関係:
  - SDFTで初期方策を改善
  - その後にRLで報酬最適化

論文でも「RL前段として自然に組み合わせ可能」と議論されている。

実験再掲: Table 1（Knowledge Acquisition）

Method	Strict	Lenient	OOD
Base	0	0	0
Oracle RAG	91	100	100
CPT	9	37	7
SFT	80	95	80
SDFT (Ours)	89	100	98

- demonstration学習でもon-policy化すると、OOD統合が強い

実験再掲: Table 2（Reasoning model）

Method	Accuracy	Avg. # of tokens
Olmo-3-7B-Think (Base)	31.2	4612
+ SFT	23.5	3273
+ SDFT (Ours)	43.7	4180

- answer-only supervisionでも、SDFTはreasoning挙動を壊しにくい

継続学習のトレードオフ

- 新タスク精度と既存能力の保持を両立できる点が主価値
- 理論セクションの主張（on-policyの重要性）と実験が一致

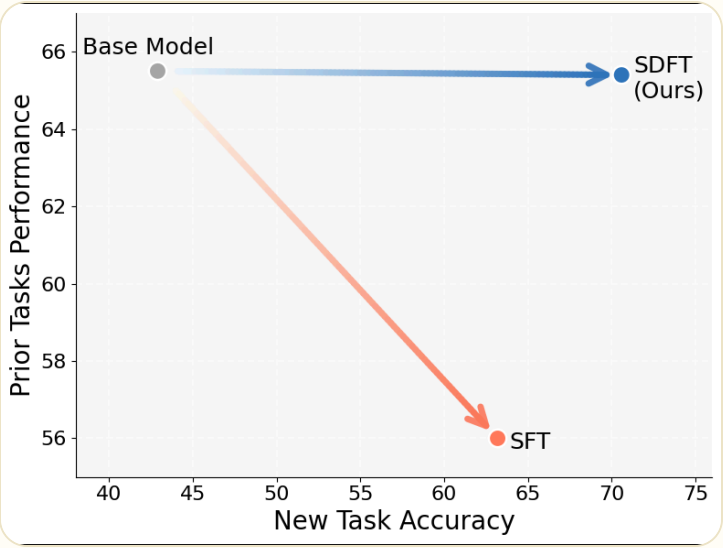

限界（理論・実装の両面）

- ICL能力依存: 小規模モデルではteacher品質が弱い
- 計算コスト増: SFT比で約2.5x FLOPs / 約4x wall-clock
- teacher由来文体アーティファクト
- 大きな行動様式変換（non-reasoning -> reasoning）は苦手

まとめ

- SDFTは「IRLの構図を、ICL teacherで実装可能化した方法」
- demonstrationのみでon-policy更新を作れるのが本質
- 継続学習文脈で、理論と実験の接続が比較的きれいな論文