Self-Distillation Enables Continual Learning 論文読みメモ

SDFT: Self-Distillation Fine-Tuning

この論文の要点

- SFTの課題: off-policy学習で忘却が起きやすい
- 提案: **SDFT**（Self-Distillation Fine-Tuning）
- 同一モデルを2役で利用
  - student:
  - teacher: （demonstration付き）
- studentのon-policy rollout上で reverse KL を最小化

手法イメージ（Figure 2）

- demonstration条件付きteacherを使って
- student自身の軌跡に対して密なtoken-level信号を返す
- reward設計なしでon-policy更新を実現

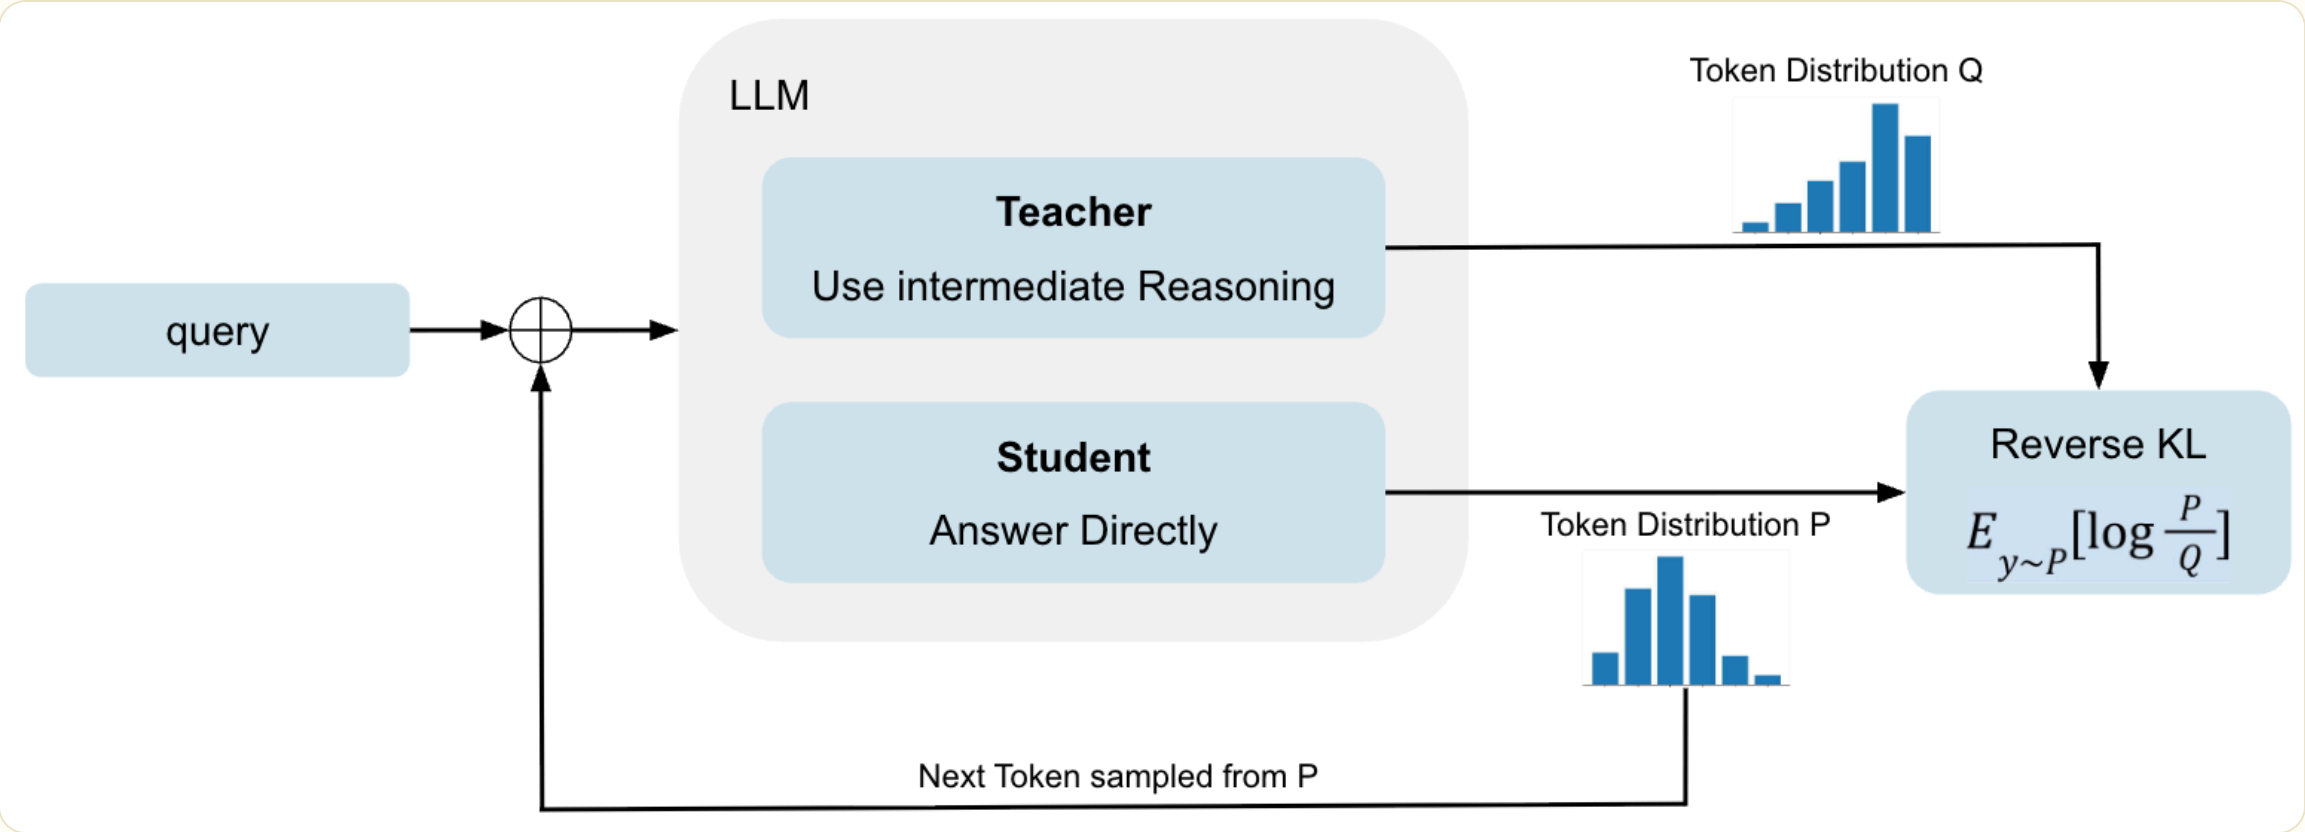

実験設定

- 主モデル: Qwen2.5-7B-Instruct
- 2設定で評価
  - Skill Learning: Science Q&A / Tool Use / Medical
  - Knowledge Acquisition: 2025年自然災害Wikipedia（約200K tokens）
- 既存能力の保持も評価
  - HellaSwag, TruthfulQA, MMLU, IFEval, Winogrande, HumanEval

Table 1: Knowledge Acquisition

Method	Strict	Lenient	OOD
Base	0	0	0
Oracle RAG	91	100	100
CPT	9	37	7
SFT	80	95	80
SDFT (Ours)	89	100	98

- SDFTはSFTより in-distribution / OOD ともに改善
- Oracle RAGに近い精度まで到達

忘却を抑えて新タスクを伸ばす

- Figure 4の読み取り
  - SDFTは新タスク精度を上げつつ既存能力を維持
  - SFTは新タスクは伸びるが既存能力が落ちる
- 継続学習の観点でPareto優位

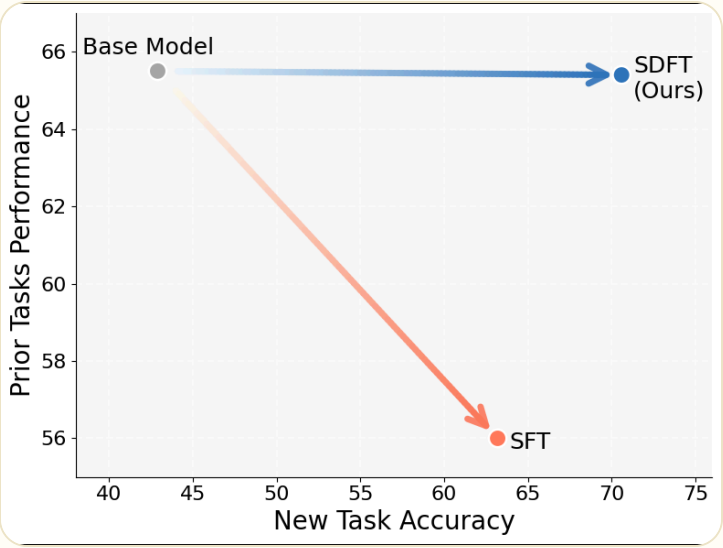

Table 2: Reasoningモデルへのanswer-only学習

Method	Accuracy	Avg. # of tokens
Olmo-3-7B-Think (Base)	31.2	4612
+ SFT	23.5	3273
+ SDFT (Ours)	43.7	4180

- SFTは精度・生成長ともに低下
- SDFTは精度改善し、reasoning挙動の崩れを抑制

限界と運用上の注意

- モデルサイズ依存
  - 小規模モデルではICL不足でteacher品質が弱い
- 計算コスト増
  - SFT比で約2.5x FLOPs / 約4x wall-clock
- 文体アーティファクト
  - teacher由来フレーズをstudentが継承する場合あり

関連研究との位置づけ

- DAgger (on-policy imitation): Ross et al., 2011
- LwF / EWC (continual learning)
- Context distillation (Bai et al., 2022)

SDFTはこれらを「ICLでteacher化した同一モデル蒸留」に接続した実装的アプローチ。

まとめ

- SDFTは「demonstrationしかない」場面で使えるon-policy学習
- 忘却を抑えながら新タスクを伸ばせる点が主価値
- 実務ではSFTの次段、またはRL前初期化として有望